

Proyecto Integrador de Machine Learning – FinanceGuard

Estudiante: Federico Ceballos Torres

Institución: Henry

Curso: Data Science – Módulo 4

Fecha: Enero 2026

Introducción

FinanceGuard es un banco digital que ha experimentado un crecimiento acelerado, alcanzando 10,000 clientes activos. Sin embargo, la dirección ha identificado un incremento preocupante en la tasa de abandono de clientes (*churn*), que actualmente se sitúa en un 20% anual. Este nivel de deserción implica pérdidas millonarias y compromete la sostenibilidad del negocio. El objetivo estratégico es reducir el churn al 15% mediante la implementación de modelos de Machine Learning que permitan identificar a los clientes con mayor probabilidad de abandonar el banco.

Para abordar este desafío, se han aplicado distintos enfoques de aprendizaje automático:

- **Modelos supervisados:** permiten predecir la probabilidad de churn a partir de variables demográficas y financieras.
- **Modelos de ensamble:** combinan múltiples algoritmos para mejorar la capacidad predictiva y la robustez del sistema.
- **Modelos no supervisados:** facilitan la segmentación de clientes y la identificación de patrones ocultos en el comportamiento.

Este reporte sintetiza los resultados obtenidos en los avances previos del proyecto, comparando el desempeño de los distintos modelos, extrayendo insights de negocio y proponiendo recomendaciones estratégicas para la reducción del churn.

Tech Stack utilizado:

El proyecto se implementó en Python, empleando librerías de ciencia de datos como *Pandas*, *NumPy*, *Scikit-learn*, *Matplotlib* y *Seaborn*. Para los modelos de boosting se utilizaron *XGBoost*, *LightGBM* y *CatBoost*. En la optimización de hiperparámetros se aplicaron técnicas de *Grid Search* y, opcionalmente, *Optuna*. Estas herramientas conforman la base tecnológica que permitió desarrollar, evaluar y comparar los distintos enfoques de Machine Learning.

1. Avance 1 – Regresión Logística (Baseline)

1.1. Performance del Modelo Baseline

El modelo de regresión logística entrenado desde cero alcanzó en el **test set**:


- **Accuracy:** 0.8100
- **Log Loss:** 0.4237
- **Precision:** 0.6080
- **Recall:** 0.1867
- **F1-Score:** 0.2857
- **ROC-AUC:** 0.7768

Matriz de Confusión (implementación propia):

```
[[1544  49]
 [ 331  76]]
```

Comparación con Scikit-Learn:

- Accuracy scratch: **0.81** vs sklearn: **0.72** (+0.09).
- Predicciones positivas scratch: **6.2%** vs sklearn: **37%**.
- Ambos enfoques confirman la validez del baseline, aunque con diferencias en calibración de probabilidades.



Interpretación:

- La curva ROC se aleja de la diagonal aleatoria, indicando que el modelo tiene buena capacidad para distinguir entre clientes que abandonan y los que permanecen.
- El AUC de 0.78 confirma que el modelo supera el azar y tiene valor predictivo razonable como baseline.
- Este resultado valida el uso de regresión logística como punto de partida para comparar con modelos más complejos en los avances siguientes.

1.2. Interpretabilidad y Coeficientes

Los coeficientes del modelo muestran las siguientes variables críticas:

- **Geography_Germany (OR ≈ 2.28)** → aumenta significativamente el riesgo de churn.
- **Age (OR ≈ 2.09)** → clientes mayores presentan mayor probabilidad de abandono.
- **Balance (OR ≈ 1.17)** → mayor saldo se asocia a mayor riesgo.
- **Gender_Male (OR ≈ 0.59)** e **IsActiveMember (OR ≈ 0.60)** → reducen el riesgo, actuando como factores protectores.
- **NumOfProducts (OR ≈ 0.93)** → menor número de productos contratados incrementa el riesgo.

1.3. Evaluación por Umbral

Umbral	Churners Detectados (TP)	Churners Perdidos (FN)	Falsas Alarmas (FP)	Recall Churn
0.5	290 / 407	117 (28.7%)	450	71.3%
0.4	343 / 407	64 (15.7%)	709	84.3%
0.3	373 / 407	34 (8.4%)	1013	91.6%

1.4. Análisis de Costos

Supuestos:

- Costo de perder un cliente (FN): **\$500**
- Costo de intervención por falso positivo (FP): **\$50**

Umbral	Costo FN	Costo FP	Costo Total
0.5	\$58,500	\$22,500	\$81,000
0.4	\$32,000	\$35,450	\$67,450
0.3	\$17,000	\$50,650	\$67,650

1.5. Fortalezas y Limitaciones del Modelo Baseline

Fortalezas:

- **Simplicidad e interpretabilidad:** La regresión logística permite explicar de manera clara el impacto de cada variable en la probabilidad de churn.
- **Rapidez de entrenamiento:** El modelo se ajusta de forma eficiente incluso con datasets grandes.
- **Base comparativa:** Sirve como baseline para evaluar mejoras posteriores con algoritmos más complejos.
- **Capacidad de calibración:** Permite ajustar umbrales de decisión según objetivos de negocio.

Limitaciones:

- **Recall inicial bajo en umbral estándar (0.5).**
- **Sensibilidad al desbalanceo de clases (80-20).**


- **Multicolinealidad moderada en algunas variables.**
- **Linealidad de relaciones:** puede simplificar patrones complejos del comportamiento de clientes.

1.6. Conclusiones y Recomendaciones de Negocio

- El **umbral 0.5 es subóptimo**: se pierden 117 clientes valiosos.
- El **umbral 0.4** logra el mejor balance costo-beneficio, reduciendo pérdidas totales.
- El **umbral 0.3** maximiza recall, útil si el costo de perder clientes es muy alto.
- Recomendación: focalizar campañas en clientes **senior**, con **balances elevados** y en **Geografía Alemania**, donde el riesgo es mayor.

1.7. Visualización de Interpretabilidad – Odds Ratios

La siguiente figura muestra los **Odds Ratios** estimados por el modelo de regresión logística, ordenados por magnitud del efecto. La línea vertical en OR = 1 indica el punto de neutralidad: valores superiores a 1 aumentan el riesgo de churn, mientras que valores inferiores a 1 lo reducen.



Interpretación:

- **Geography_Germany (OR ≈ 2.28)** y **Age (OR ≈ 2.09)** son los predictores más críticos, duplicando el riesgo de churn.
- **Gender_Male (OR ≈ 0.59)** e **IsActiveMember (OR ≈ 0.60)** reducen significativamente la probabilidad de abandono.
- **Balance (OR ≈ 1.17)** incrementa moderadamente el riesgo, mientras que **NumOfProducts (OR ≈ 0.93)** lo reduce.
- Variables como **EstimatedSalary**, **Geography_Spain**, **HasCrCard** y **Tenure** muestran efectos más leves, cercanos a la neutralidad.


Este gráfico refuerza la capacidad del modelo baseline no solo para predecir, sino también para **explicar** qué factores influyen en la decisión de los clientes de abandonar el banco.

2. Avance 2 – Gradient Boosting y Ensambles

2.1. Performance Comparativa en Conjunto de Validación

Se evaluaron los modelos base (**Random Forest, XGBoost, LightGBM, CatBoost**) y distintas variantes de optimización y ensamble (**Grid Search, Random Search, Optuna, Stacking, Blending**). Los resultados se resumen a continuación:

Modelo	Accuracy	ROC-AUC	Precision	Recall	F1-score
Random Forest	0.8544	0.8515	0.7569	0.4202	0.5404
XGBoost	0.8581	0.8433	0.7302	0.4816	0.5804
LightGBM	0.8625	0.8564	0.7573	0.4785	0.5865
CatBoost	0.8662	0.8656	0.7857	0.4724	0.5900
XGBoost (Grid Search)	0.7930	0.8654	0.4943	0.7469	0.5949
Stacking (manual, CV)	0.8290	0.8664	0.5649	0.6953	0.6233
Blending Simple	0.8575	0.8682	0.7007	0.5233	0.5992
Blending con Holdout	0.8330	0.8644	0.5743	0.6929	0.6281
Blending con Ponderación Óptima	0.8575	0.8682	0.7007	0.5233	0.5992
XGBoost (Random Search)	0.8665	0.8621	0.7778	0.4816	0.5948
XGBoost (Optuna, Bayesian Opt.)	0.8675	0.8694	0.7886	0.4767	0.5942



Interpretación:

- En comparación con el baseline de regresión logística (ROC-AUC ≈ 0.7768), todos los modelos de boosting muestran mejoras sustanciales en discriminación y precisión.
 - **CatBoost** fue el mejor modelo base, destacando en Accuracy, Precision y ROC-AUC.
 - **XGBoost optimizado con Grid Search** logró el mayor Recall (0.7469), siendo útil para maximizar detección de churners.
 - **Blending con Holdout** y **Stacking** ofrecieron el mejor equilibrio entre Recall y F1-Score, mostrando que los ensambles pueden superar a modelos individuales en cobertura.
 - **Optuna (Bayesian Optimization)** alcanzó el mejor ROC-AUC (0.8694) y la mayor Precision (0.7886), validando la utilidad de optimización avanzada.
-

2.2. Interpretabilidad – Feature Importance

Los modelos de boosting identificaron las siguientes variables como más influyentes en la predicción de churn:

- **Age** y **Balance** se confirman como predictores críticos.
 - **Geography_Germany** mantiene un peso alto, reflejando diferencias de mercado.
 - **NumOfProducts** y **IsActiveMember** actúan como factores protectores.
-

2.3. Fortalezas y Limitaciones

Fortalezas:

- Mayor capacidad predictiva frente al baseline.
- Robustez frente a multicolinealidad y relaciones no lineales.
- Flexibilidad para ajustar hiperparámetros y mejorar desempeño.
- Los ensambles (Stacking/Blending) mejoran Recall y F1-Score, equilibrando precisión y cobertura.

Limitaciones:

- Mayor complejidad y menor interpretabilidad que la regresión logística.
 - Requiere mayor poder computacional y tiempo de entrenamiento.
 - La importancia de variables es relativa y no siempre equivalente a causalidad.
-

2.4. Conclusiones y Recomendaciones de Negocio


- Los modelos de boosting ofrecen mejoras sustanciales en precisión y discriminación frente al baseline.
- **CatBoost** es el más confiable para producción si se prioriza precisión y estabilidad.
- **XGBoost optimizado (Grid Search)** es recomendable si el objetivo es maximizar Recall (detección de churners).
- **Blending con Holdout** y **Stacking** son alternativas sólidas para equilibrar Recall y F1-Score, maximizando cobertura sin sacrificar demasiado la precisión.
- La optimización avanzada con **Optuna** mostró el mejor ROC-AUC y Precision, siendo una técnica recomendable para futuros proyectos.


- Estrategia sugerida: combinar un modelo de alta precisión (CatBoost/Optuna) con un ensamble que maximice Recall, logrando un sistema híbrido que optimice recursos de retención.

3. Avance 3 – Aprendizaje No Supervisado

3.1. Segmentación con K-Means

Se aplicó K-Means al dataset de clientes, identificando **4 clusters principales**. Cada cluster representa un segmento con características demográficas y de comportamiento diferenciadas. La tasa de churn (**Exited**) se calculó por cluster, mostrando que el **Cluster 1** concentra el mayor riesgo de abandono.





Interpretación técnica:

- El método del codo sugiere **K = 4** como punto óptimo de segmentación.
 - El coeficiente de silueta alcanza su máximo en **K = 2**, pero mantiene un valor aceptable en **K = 4**, lo que indica buena cohesión y separación.
 - Se eligió **K = 4** por su balance entre calidad estructural y riqueza interpretativa.
-

3.2. Características de cada segmento


Cluster	Perfil del Cliente	Tasa de Churn
0	Jóvenes, balances bajos, baja tasa de churn	~15%
1	Alta antigüedad, balances elevados, mayor riesgo	~45%
2	Ingresos medios, productos múltiples, churn moderado	~25%
3	Ingresos altos, baja actividad, churn reducido	~10%

Estos perfiles permiten identificar segmentos críticos y orientar estrategias de retención.

3.3. Visualización de Clusters – PCA 3D con K-Means

La siguiente figura muestra la distribución de los clientes en el espacio reducido por PCA, coloreados según su asignación de cluster:

Visualización PCA en 3D con clusters K-Means (K=4)




3.4. Insights de Negocio por Cluster

- **Cluster 1:** Segmento de alto riesgo. Clientes con balances elevados y antigüedad, pero alta tasa de abandono. Requieren intervención urgente.
 - **Cluster 0:** Clientes jóvenes con bajo saldo. Riesgo moderado. Potencial para fidelización temprana.
 - **Cluster 2:** Clientes con múltiples productos e ingresos medios. Churn intermedio. Requieren seguimiento.
 - **Cluster 3:** Clientes con ingresos altos y baja actividad. Bajo riesgo, pero podrían ser incentivados a aumentar engagement.
-

3.5. Exploración Complementaria – DBSCAN

Además de K-Means, se aplicó DBSCAN para detectar clientes con comportamiento atípico. Esta técnica permite identificar clusters con formas irregulares y puntos de ruido que no encajan en ningún grupo tradicional.

Visualización PCA en 3D con clusters DBSCAN



Interpretación:

- DBSCAN identificó grupos compactos y varios clientes como outliers.
- Se generó la variable `IsOutlier_DBSCAN` para marcar estos casos.
- Esta información complementa la segmentación de K-Means y permite detectar perfiles de churn menos frecuentes pero relevantes.

3.6. Features Derivadas del Clustering

Se generaron variables adicionales para enriquecer el pipeline supervisado:

- **Cluster_KMeans**: asignación de cluster para cada cliente.
- **ClusterRisk**: indicador binario de riesgo según tasa de churn del cluster.
- **IsOutlier_DBSCAN**: marca clientes con comportamiento atípico.
- **Balance_ClusterMean** / **Age_ClusterMean**: contextualizan al cliente respecto a su grupo.

Estas variables permiten que los modelos supervisados integren información estructural no supervisada, mejorando la capacidad predictiva y la interpretabilidad.

3.7. Conclusiones del Avance

Este avance consolidó la transición entre lo **exploratorio** y lo **predictivo**:

- La segmentación no supervisada reveló patrones ocultos en el comportamiento de los clientes.
 - Se aplicaron PCA y t-SNE para visualizar la estructura interna de los datos.
 - K-Means y DBSCAN permitieron identificar clusters diferenciados y clientes atípicos.
 - Se generaron features derivadas que enriquecen el dataset y serán utilizadas en modelos supervisados.
 - El trabajo sienta las bases para el próximo avance, donde se entrenarán modelos que integren estas nuevas variables para mejorar la precisión y la capacidad de acción en la retención de clientes.
-
-

4. Avance Extra Credit – Optimización de Threshold y Costos Personalizados

4.1. Blending con Holdout (Validación, threshold=0.5)


- **Accuracy**: 0.84
- **ROC-AUC**: 0.865
- **Precision**: 0.592
- **Recall**: 0.693
- **F1-score**: 0.638

Matriz de Confusión (Validación, threshold=0.5):

```
[[1118 156]  
 [ 100 226]]
```

4.2. Threshold Óptimo (Validación)

- **Threshold**: 0.27
- **Costo mínimo**: 969
- **Recall**: 0.929
- **Precision**: 0.327
- **F1-score**: 0.484



4.3. Blending con Holdout (Test con Threshold Óptimo)

- **Accuracy:** 0.606
- **ROC-AUC:** 0.867
- **Precision:** 0.332
- **Recall:** 0.924
- **F1-score:** 0.488

Matriz de Confusión (Test, threshold=0.27):

[[836 757]
[31 376]]

Análisis Final – Mejor Modelo Supervisado (Blending con Holdout)

El modelo de **Blending con Holdout** se consolida como la mejor estrategia supervisada, al combinar múltiples clasificadores y ajustar un meta-modelo sobre un conjunto de validación interno. Esto permite aprovechar la diversidad de los modelos base y obtener un desempeño más robusto.

Comparación de Thresholds

Conjunto	Threshold	Accuracy	ROC-AUC	Precision	Recall	F1-score
----------	-----------	----------	---------	-----------	--------	----------

Conjunto	Threshold	Accuracy	ROC-AUC	Precision	Recall	F1-score
Validación	0.5	0.840	0.865	0.592	0.693	0.638
Validación	0.27	0.596	0.865	0.327	0.929	0.484
Test	0.5	0.837	0.867	0.582	0.708	0.639
Test	0.27	0.606	0.867	0.332	0.924	0.488

Interpretación de Negocio

- Con **threshold 0.5**, el modelo mantiene un buen equilibrio entre precisión y recall, pero deja escapar una proporción significativa de clientes en riesgo (FN elevados).
- Con **threshold 0.27**, el modelo maximiza la detección de churners (Recall > 92%), reduciendo drásticamente los falsos negativos, aunque a costa de un mayor número de intervenciones adicionales (Precision ≈ 33%).
- El costo total se minimiza en el threshold 0.27, dado que un FN es 15 veces más costoso que un FP.

Conclusión

El **Blending con Holdout con threshold optimizado (0.27)** representa el mejor compromiso entre sensibilidad y costo operativo. Este ajuste permite alinear el modelo con el objetivo estratégico de **FinanceGuard: reducir la tasa de churn del 20% al 15% anual**, priorizando la detección de clientes en riesgo y aceptando un mayor volumen de intervenciones como inversión necesaria.

5. Lecciones Aprendidas y Consideraciones Futuras

5.1. ¿Cuándo usar modelos supervisados vs no supervisados?

Modelos supervisados (ej. regresión logística, boosting, ensambles):

- Se utilizan cuando existe una **variable objetivo clara** (ej. churn = 1/0).
- Permiten medir desempeño con métricas cuantitativas (Accuracy, Recall, ROC-AUC).
- Son adecuados para **predicción operativa**, donde el objetivo es anticipar qué clientes abandonarán.
- Ventaja: alta capacidad predictiva y posibilidad de calibrar umbrales para objetivos de negocio.
- Limitación: requieren datos históricos etiquetados y pueden perder interpretabilidad si son muy complejos.

Modelos no supervisados (K-Means, DBSCAN):

- Se aplican cuando no existe una etiqueta clara o se busca **descubrir patrones ocultos**.
- Útiles para **segmentación exploratoria**, identificación de perfiles de clientes y detección de outliers.
- Aportan valor en la **interpretación estratégica**, revelando grupos con diferentes riesgos y comportamientos.
- Ventaja: enriquecen el feature engineering y permiten diseñar estrategias diferenciadas.
- Limitación: no predicen directamente el churn, sino que complementan el análisis.

Conclusión:

- Los modelos supervisados son la base para la predicción y acción inmediata.
 - Los modelos no supervisados aportan contexto y enriquecen la interpretación, generando variables adicionales que mejoran los modelos supervisados.
 - La combinación de ambos enfoques potencia la precisión y la relevancia de las recomendaciones de negocio.
-

5.2. Consideraciones para futuros proyectos de churn

- **Balance de clases:** aplicar técnicas de oversampling/undersampling o ajustar umbrales para mejorar Recall sin sacrificar Precision.
 - **Regularización y complejidad:** considerar modelos penalizados (Ridge/Lasso) para mitigar multicolinealidad en regresión logística.
 - **Integración de features derivadas:** usar variables de clustering (`Cluster_KMeans`, `ClusterRisk`, `IsOutlier_DBSCAN`) como insumos en modelos supervisados.
 - **Exploración de modelos avanzados:** evaluar redes neuronales o modelos híbridos si se dispone de más datos y recursos.
 - **Interpretabilidad ejecutiva:** mantener visualizaciones claras (ROC, importancia de variables, clusters) para comunicar resultados a audiencias no técnicas.
 - **Ciclo iterativo:** validar continuamente métricas y ajustar modelos según objetivos de negocio (ej. maximizar recall vs optimizar precisión).
 - **Escalabilidad:** preparar pipelines reproducibles que permitan actualizar modelos con nuevos datos sin perder trazabilidad.
-

5.3. Síntesis Final

El proyecto mostró que:

- La **regresión logística** es un baseline sólido y explicativo.
 - Los **modelos de boosting** mejoran sustancialmente la capacidad predictiva.
 - La **segmentación no supervisada** aporta insights estratégicos y nuevas variables para enriquecer el pipeline.
 - La combinación de enfoques supervisados y no supervisados es clave para construir soluciones de churn robustas, interpretables y accionables.
-
-
-